

David Lucas Oliveira dos Santos, Enzo de Oliveira da Silva, Italo Fraga
Botelho, Maximus Daniel Nascimento, Maysa Fernanda Araujo, Vitória
Katerine Ferreira

JUSTIFICATIVA DA METODOLOGIA DE GESTÃO DE PROJETO

Documento de fundamentação metodológica do projeto Miop.IA

Campinas
2026

David Lucas Oliveira dos Santos, Enzo de Oliveira da Silva, Italo Fraga Botelho, Maximus Daniel Nascimento, Maysa Fernanda Araujo, Vitória Katerine Ferreira

JUSTIFICATIVA DA METODOLOGIA DE GESTÃO DE PROJETO

Documento de fundamentação metodológica do projeto Miop.IA

Documento de fundamentação metodológica do projeto Miop.IA submetido à Residência em Inteligência Artificial.

INSTITUTO DE PESQUISAS ELDORADO
PONTIFÍCIA UNIVERSIDADE CATÓLICA DE CAMPINAS (PUC-CAMPINAS)
Residência em Inteligência Artificial
Miop.IA

Campinas
2026

1 INTRODUÇÃO

Este documento tem como objetivo apresentar e justificar a metodologia de gestão de projeto adotada pelo grupo Miop.IA, respondendo à Big Idea levantada em sala: "Por que a metodologia proposta seria a mais adequada para o nosso projeto?". O projeto Miop.IA envolve o desenvolvimento de uma extensão apoiada em inteligência artificial para estímulo do senso crítico do usuário diante de notícias tendenciosas, contando com um prazo curto (sete semanas) e múltiplas frentes de trabalho paralelas, como levantamento de dados, modelagem, desenvolvimento da extensão e validação com usuários.

Para orientar a escolha, o grupo estabeleceu previamente critérios de decisão, entre eles a adaptabilidade da metodologia ao modelo e ao plano de trabalho do projeto, a viabilidade de execução dentro da janela de tempo disponível e a capacidade de cobrir, de ponta a ponta, as dezoito guiding constraints definidas para o projeto.

2 METODOLOGIAS AVALIADAS

Como base de comparação para a estrutura organizacional, foram levantadas quatro alternativas que efetivamente aparecem no Quadro 3.1:

- Cascata;
- Scrum;
- Kanban;
- Scrumban.

A comparação foi restrita às metodologias que constam do levantamento organizacional. As demais abordagens utilizadas posteriormente nos Slots B, C e D são tratadas como métodos específicos de cada etapa e são referenciadas nos respectivos quadros, evitando misturar metodologias de gestão do projeto com métodos de descoberta, dados/IA e validação.

3 METODOLOGIA ORGANIZACIONAL ESCOLHIDA: SCRUMBAN COMO ESTRUTURA GUARDA-CHUVA

O Scrumban foi definido pelo grupo como a estrutura de gestão do projeto (Slot A coordenação da execução ao longo das sete semanas), por combinar a estrutura temporal do Scrum com a visualização e o fluxo contínuo do Kanban. Essa escolha é coerente com a literatura que descreve o Scrumban como uma abordagem híbrida entre Scrum e Kanban, adequada quando se busca equilibrar previsibilidade e adaptação. [1]

3.1 Justificativa da escolha

A existência de diversas frentes de trabalho paralelas favorece o uso de um fluxo visual, com limites de trabalho em andamento e identificação de gargalos, características centrais do Kanban. [2] No entanto, o prazo fixo de sete semanas exige marcos de abertura e fechamento; por isso, a equipe mantém a cadência temporal do Scrum sem importar toda a sua burocracia. O Scrumban funciona, assim, como guarda-chuva de coordenação, enquanto os Slots B, C e D especializam o trabalho por objetivo.

A guiding question "será que cada fase de desenvolvimento exige uma metodologia diferente?" levou à adoção da estrutura híbrida. A decisão não significa aplicar várias metodologias simultaneamente a todas as tarefas: cada Slot possui um objetivo, uma estratégia de abertura, um critério de fechamento e uma responsabilidade principal. Essa separação reduz a sobreposição metodológica e torna a hibridização auditável.

O Quadro 3.1 sintetiza o levantamento organizacional e explicita as fontes que sustentam as vantagens, limitações e decisões registradas.

Metodologia	Vantagens	Desvantagens no contexto de IA	Motivo da escolha/rejeição
Scrum tradicional	Forte previsibilidade, papéis bem definidos e rituais claros. [12]	Excesso de burocracia (estimativas em story points, restrições rígidas de escopo de sprint); projetos de IA sofrem com alta incerteza técnica inicial. [12]	Parcialmente adaptado: aproveitada a cadência de entregas e os rituais, descartada a rigidez burocrática.
Kanban puro	Máxima flexibilidade, foco em fluxo contínuo e gerenciamento de gargalos por WIP. [2]	Pode faltar cadência de marcos temporais bem definidos, crítica para um prazo fixo de sete semanas. [2]	Parcialmente adaptado: mantido o board visual e o controle de fluxo, adicionados marcos temporais.
Cascata	Planejamento detalhado de ponta a ponta e documentação prévia. [13]	Totalmente inviável para IA; erros de dados ou limitações descobertas tardiamente comprometem todo o projeto. [13]	Rejeitada: incompatível com a natureza exploratória e iterativa do desenvolvimento de machine learning.
Scrumban	Mantém o ritmo organizado e os ciclos de feedback do Scrum, com a flexibilidade de puxar tarefas (pull system) do Kanban. [12]	Exige maturidade da equipe para autogerenciamento do fluxo sem microgerenciamento. [12]	Escolhida: elimina estimativas complexas, mitiga a imprevisibilidade técnica de IA e mantém a disciplina de entregas semanais sem burocracia excessiva.

Fonte: elaborado pelo grupo Miop.IA (2026), com vantagens e limitações fundamentadas em [1], [2], [12] e [13].

Quadro 3.1 – Comparação entre metodologias de gestão avaliadas

4 ESTRUTURA HÍBRIDA EM SLOTS METODOLÓGICOS

A estrutura híbrida foi revisada para evitar sobreposição excessiva entre métodos. O Scrumban permanece como guarda-chuva de coordenação (Slot A); o Slot B concentra descoberta e diagnóstico; o Slot C concentra dados e IA; e o Slot D concentra validação e evidência de impacto. A entrada de uma técnica em um Slot não altera automaticamente os demais: qualquer mudança de escopo metodológico deve ser registrada no apêndice de decisões.

4.1 Slot B - Diagnóstico do problema e da comunidade real: Design Thinking + Double Diamond + MASP

O Design Thinking permanece no início do projeto porque trabalha a compreensão das pessoas e do contexto, a geração de alternativas, a prototipação e o teste. [5] O Double Diamond passa a ser tratado como estrutura complementar de divergência e convergência, com as etapas Discover, Define, Develop e Deliver. [4] As ações de campo foram pautadas nessa fase, buscando compreender as reais necessidades do público-alvo antes de qualquer desenvolvimento técnico.

A aplicação do método também contribuiu para a percepção de que a ferramenta poderia colocar o usuário em uma posição passiva diante do conteúdo. A partir dessa constatação, o grupo levantou possibilidades de layout que incentivassem o usuário a construir senso crítico diante de notícias tendenciosas, em vez de apenas receber um veredito automático.

O Double Diamond organiza o fluxo de descoberta e desenvolvimento, enquanto o MASP é mantido apenas como ferramenta de análise estruturada de causas. Essa divisão evita que os três métodos sejam tratados como três processos completos executados em paralelo. O MASP possui oito etapas e é usado aqui como apoio para aprofundar a causa-raiz do problema identificado. [6]

O fechamento do Slot B ocorre quando o problema está delimitado, as necessidades do usuário estão registradas, as principais hipóteses de solução foram priorizadas e existe um protótipo ou representação suficiente para iniciar o trabalho técnico. A abertura de uma nova rodada de descoberta só ocorre quando evidência de teste contradiz a hipótese vigente.

4.2 Slot C - Processo técnico de dados e IA: CPMAI como referência principal, com CRISP-DM e SEMMA como referências complementares

O CRISP-DM continua sendo utilizado como referência do ciclo de vida de mineração de dados, especialmente para orientar entendimento, preparação, modelagem, avaliação e implano. A documentação da IBM ressalta que suas fases não precisam ser executadas de forma estritamente linear e podem ser revisitadas conforme os resultados. [2]

O CPMAI foi mantido como referência principal de gestão do ciclo de vida de IA porque possui seis fases voltadas a projetos de IA, incluindo entendimento do negócio, necessidades de dados, preparação, desenvolvimento iterativo, avaliação e operacionalização. [3] O SEMMA não será tratado como uma terceira metodologia concorrente: será usado somente como referência operacional para Sample, Explore, Modify, Model e Assess nas atividades de dados/modelagem. [7]

O Quadro 4.1 resume a comparação entre CRISP-DM e CPMAI e indica as fontes das características atribuídas a cada abordagem.

Critério	CRISP-DM	CPMAI
Foco principal	Mineração de dados: extrair, limpar e entender padrões para gerar conhecimento. [2]	Gestão do projeto de IA como um todo, incluindo aprendizado do modelo, interação com o usuário e operação em produção. [3]
Cobertura ética e regulatória	Não contempla nativamente.	Camadas obrigatórias de avaliação de viés, conformidade com a LGPD e ética no uso da IA. [3]
Compatibilidade ágil	Exige esforço manual de adaptação ao método ágil.	Nativamente ágil, pensado para sprints e Kanban. [3]
Papel no projeto	Referência para o ciclo de vida dos dados. [2]	Estrutura escolhida para gerenciar o projeto de IA de ponta a ponta, com critérios de governança, explicabilidade, segurança e melhoria contínua. [3]

Quadro 4.1 – Comparação entre CRISP-DM e CPMAI

O SEMMA será utilizado como apoio operacional nas atividades de preparação e modelagem, sem criar um novo fluxo paralelo ao CPMAI. Sua contribuição é limitada às atividades Sample, Explore, Modify, Model e Assess. [7] A decisão reduz a sobreposição metodológica e preserva o CPMAI como referência principal do Slot C.

O Quadro 4.2 foi revisado para mostrar não apenas a fase planejada por semana, mas também o ponto de abertura, o critério de fechamento e o nível de maturidade esperado. Isso permite avaliar se uma estratégia está apenas sendo iniciada ou se já produziu evidência suficiente para ser encerrada.

Período	Fase CPMAI	Foco principal no tiro curto	Critério de abertura / Fechamento
Semana 1	1. Business Understanding	Definir o problema comercial e alinhar expectativas; estabelecer Go/No-Go.	Problema, hipótese e critérios de sucesso definidos.
Semana 2	2. Data Understanding	Auditar os dados e, se necessário, pivotar a fonte.	Auditoria de disponibilidade, qualidade e adequação iniciada.
Semana 3	3. Data Preparation	Limpar, filtrar e estruturar o mínimo necessário para o MVP.	Dataset selecionado e pipeline mínimo estabelecido.
Semanas 4 e 5	4. Model Development	Treinar baselines e candidatos, evitando complexidade desnecessária.	Baseline e hipótese de modelagem definidos.
Semana 6	5. Model Evaluation	Avaliar métricas, erros e feedback de usuários.	Modelo candidato e protocolo de avaliação executados.
Semana 7	6. Model Operationalization	Disponibilizar forma simplificada de uso e planejar próximos passos.	Modelo aprovado para uma forma simplificada de implantação.

Fonte: elaborado pelo grupo Miop.IA (2026), com base em [2], [3] e [7].

Quadro 4.2 – Cronograma das fases do CPMAI no projeto Miop.IA

Riscos da rolagem de semanas (pivotagem): a pivotagem entre semanas é permitida, mas não pode ser usada como mecanismo de adiamento indefinido. Os principais riscos são perda de trabalho já realizado, quebra de rastreabilidade, redução da janela de validação, reprocessamento do pipeline e compressão das semanas 4-6. Para controlar o risco, toda pivotagem deverá registrar motivo, evidência, impacto, custo de mudança e novo critério de fechamento. O risco é aceitável apenas quando a estratégia anterior deixa de atender ao objetivo ou aos dados disponíveis.

Durante a Semana 2, a estratégia de dados foi refinada. Após a auditoria de disponibilidade e aderência ao objetivo do projeto, o grupo consolidou o uso do Fake.br Corpus. A escolha é justificada pela sua maturidade, pareamento léxico-semântico e tamanho. O corpus utilizado possui originalmente 7.200 notícias em português (sendo 3.600 verdadeiras e 3.600 falsas), publicadas até 2018. Como este dataset original apresenta riscos de obsolescência temporal (data shifting) para o cenário de 2026, o projeto engloba a Engenharia Reversa deste corpus para a estruturação de uma nova base de dados atualizada, que alimentará os testes de aprendizado não supervisionado. [9]

O tratamento dos dados textuais será realizado em Python. Durante a Fase 0 de auditoria, a equipe constatou que as features originais do corpus dependiam de ferramentas legadas (NLNet e NLTK), o que gerava risco de choque de distribuição (data shift). Portanto, adotou-se o modelo `pt_core_news_lg` da biblioteca spaCy para recalculá-las todas as features morfosintáticas e estilométricas de forma determinística. A etapa de preparação

de dados (Data Preparation) aplicará a técnica de Estudo de Ablação (Ablation Study), particionando os dados em 8 cenários distintos para isolar e mitigar vieses algorítmicos, como o vazamento de dados (data leakage) por metadados de autoria e o viés de extensão de texto (length bias). [2][7]

A estratégia de classificação também foi ajustada para respeitar o esquema efetivamente disponível no corpus escolhido. A variável principal será a veracidade, com duas classes: Verdadeira e Falsa. As cinco categorias temáticas do FakeTrueBR Brasil, política, entretenimento, saúde e mundo serão tratadas como atributo temático separado, e não como classes de veracidade. [9] Isso evita misturar conceitos diferentes: uma notícia pode pertencer a uma categoria temática e, simultaneamente, ser verdadeira ou falsa. Se futuramente houver evidência de que uma notícia deve receber mais de uma categoria temática, essa dimensão poderá ser modelada como multi-rótulo; não é recomendável alterar para multi-rótulo sem que a anotação de origem sustente essa decisão. A literatura mostra que tarefas de classificação multirrótulo são adequadas quando uma mesma instância possui simultaneamente mais de um rótulo conceitual, mas essa escolha deve decorrer do esquema de anotação. [10]

Para análise exploratória de temas, poderá ser utilizado Topic Modeling por LDA como técnica não supervisionada complementar, sem transformá-lo em classe-alvo. O LDA representa documentos como misturas de tópicos latentes e é apropriado para explorar estrutura temática em corpora textuais. [11] A inclusão de Fairness permanece como requisito de avaliação do pipeline, especialmente para verificar se diferenças de distribuição entre categorias ou grupos não introduzem efeitos indevidos no modelo.

4.3 Slot D - Validação e evidência de impacto: Lean Startup e técnicas complementares

Para a validação com o usuário, o grupo mantém o Lean Startup como lógica de experimentação: construir uma versão mínima, medir a resposta dos usuários e aprender com os resultados para decidir entre perseverar ou pivotar. [8] As técnicas do Quadro 4.3 são tratadas como técnicas de validação, e não como novas metodologias de gestão.

Técnica	Foco principal	Esforço de engenharia	Aplicação no Miop.IA
Design Sprint (Google)	Usabilidade e interface (UX). [14]	Zero.	Apresentar telas simuladas ao público com baixa acuidade visual, validando a legibilidade do layout antes de escrever código.
Mágico de Oz	Percepção de valor e senso crítico. [15]	Baixo (apenas frontend).	A extensão recebe o texto, mas a análise é feita manualmente por um integrante do grupo, que digita um questionamento útil ao usuário testador, validando se a intervenção estimula o pensamento crítico.
Shadow Mode (modo sombra) AI TRISM/Red Teaming	Acurácia estatística (backend). [16] Segurança, ética e viés. [17]	Alto (pipeline de dados completo). Alto (testes de estresse).	O motor de ETL e os algoritmos rodam passivamente em segundo plano no navegador de um grupo de controle, registrando como classificariam a página sem exibir alertas, validando a modelagem com dados reais sem expor o usuário a erros. Bombardear o modelo treinado com amostras polarizadas para forçar falhas e garantir conformidade com a LGPD e com os aspectos éticos do uso da IA.
Lean Startup (A/B Testing)	Adoção e retenção (mercado). [8][18]	Médio (integração full-stack).	Lançamento do protótipo funcional para a comunidade real nas semanas finais, medindo o engajamento dos usuários com as orientações do sistema para gerar evidências de impacto.

Fonte: elaborado pelo grupo Miop.IA (2026), com base em [8], [14], [15], [16], [17] e [18].

Quadro 4.3 – Técnicas de validação avaliadas para o Slot D

5 CONSIDERAÇÕES FINAIS

A metodologia híbrida revisada mantém o Scrumban como guarda-chuva de coordenação, o Slot B como combinação delimitada de Design Thinking, Double Diamond e MASP, o CP-MAI como referência principal do Slot C com CRISP-DM e SEMMA como complementos, e o Lean Startup como lógica de validação no Slot D.

A principal mudança metodológica foi a explicitação dos critérios de abertura/fechamento por semana e a substituição do dataset inicialmente previsto pelo FakeTrueBR. A mudança foi necessária para alinhar o pipeline ao esquema de dados efetivamente utilizado e para evitar que classes de veracidade fossem confundidas com categorias temáticas.

Como regra de governança, qualquer alteração futura de metodologia, dataset, classe-alvo ou estratégia de validação deverá ser acompanhada de justificativa no Apêndice A, indicando: decisão anterior, evidência que motivou a mudança, impacto esperado, risco introduzido e critério para avaliar se a nova decisão deve permanecer.

REFERÊNCIAS

- [1] SCRUM ALLIANCE. Scrumban: hybrid approach combining Scrum structure and Kanban visualization. 2026. Disponível em:
<https://resources.scrumalliance.org/Article/scrumban>
- [2] IBM. CRISP-DM Help Overview. IBM Documentation. Disponível em: <https://www.ibm.com/docs/en/spss-modeler/saas?topic=dm-crisp-help-overview>
- [3] PROJECT MANAGEMENT INSTITUTE (PMI). PMI Certified Professional in Managing AI (PMI-CPMAI). Disponível em:
<https://www.pmi.org/certifications/ai-project-management-cpmai>
- [4] DESIGN COUNCIL. The Double Diamond. Disponível em:
<https://www.designcouncil.org.uk/resources/the-double-diamond/>
- [5] IDEO. Design Thinking: Human-Centered Innovation. Disponível em:
<https://designthinking.ideo.com/process>
- [6] UNIVERSIDADE DE SÃO PAULO (USP). Método de Análise e Solução de Problemas (MASP). Disponível em:
<https://sistemas.eel.usp.br/bibliotecas/monografias/2018/MEP18015.pdf>
- [7] SAS. Data Mining and SEMMA. SAS Enterprise Miner Documentation. Disponível em: <https://support.sas.com/documentation/cdl/en/emcs/66392/HTML/default/n0pejm83csbj4n1xueveo2uoujy.htm>
- [8] LEAN STARTUP CO. Build-Measure-Learn / Validated Learning. Disponível em:
<https://leanstartup.co/principles/validated-learning/>
- [9] CHAVARRO, J. P.; CARVALHO, J. T.; PORTELA, T. T.; CARDOSO-SILVA, J. FakeTrueBR: Um corpus brasileiro de notícias falsas. Escola Regional de Banco de Dados, 2023. DOI: 10.5753/erbd.2023.229495. Disponível em:
<https://github.com/jpchav98/FakeTrue.Br>
- [10] MORAIS, J. I. Classificação multirrótulo de notícias considerando sua legitimidade e objetividade. Universidade Estadual de Londrina. Disponível em:
<https://repositorio.uel.br/items/6f61a8cf-785b-4c0c-9ab4-feb91214be87>
- [11] BLEI, D. M.; NG, A. Y.; JORDAN, M. I. Latent Dirichlet Allocation. Journal of Machine Learning Research, v. 3, p. 993-1022, 2003. Disponível em:
<https://www.jmlr.org/papers/v3/blei03a.html>
- [12] ATLASSIAN. O que é o Scrum? Guia para a estrutura ágil. Disponível em:
<https://www.atlassian.com/br/agile/scrum>

[13] IBM. CRISP-DM Help Overview - referência usada para contrastar processos iterativos de dados com o risco de um fluxo rígido. Disponível em: <https://www.ibm.com/docs/en/spss-modeler/saas?topic=dm-crisp-help-overview>

[14] GOOGLE DESIGN. 5-Day UX Design Sprint / Design Sprint Kit. Disponível em: <https://design.google/library/design-sprints>

[15] SCIENCEDIRECT. Wizard of Oz Prototypes. Disponível em: <https://www.sciencedirect.com/topics/computer-science/physical-prototype>

[16] AWS. Minimize the production impact of ML model updates with Amazon SageMaker shadow testing. 2022. Disponível em: <https://aws.amazon.com/blogs/machine-learning/minimize-the-production-impact-of-ml-model-updates-with-amazon-sagemaker-shadow-te>

[17] IBM. What is AI TRISM? Disponível em: <https://www.ibm.com/br-pt/think/topics/ai-trism>

Apêndices

1 JUSTIFICATIVAS DAS ALTERAÇÕES

A.1 - Remoção das metodologias RAD, DSDM e Go Horse

A lista de metodologias avaliadas para a coordenação organizacional foi reduzida às quatro que aparecem no Quadro 3.1: Cascata, Scrum, Kanban e Scrumban. Justificativa: eliminar metodologias citadas no texto sem correspondente no quadro de levantamento, aumentando a rastreabilidade entre narrativa e evidência.

A.2 - Fontes das vantagens e desvantagens

As vantagens e limitações do Quadro 3.1 passaram a receber referências. Justificativa: as características metodológicas não devem aparecer como afirmações sem origem; as fontes foram registradas também no diretório resources.

A.3 - Revisão da estrutura híbrida em Slots

A estrutura passou a explicitar que cada Slot possui objetivo, abertura e fechamento próprios. Justificativa: a hibridização deixa de ser uma soma de metodologias e passa a ser uma arquitetura de trabalho com responsabilidades delimitadas.

A.4 - Referências do Quadro 4.1

As afirmações sobre CRISP-DM, CPMAI e SEMMA foram vinculadas às respectivas fontes. Justificativa: diferenciar o que é descrição da metodologia, o que é adaptação do grupo e o que é decisão de projeto.

A.5 - Maturidade e fechamento no Quadro 4.2

O cronograma ganhou critérios de abertura, fechamento e maturidade. Justificativa: uma estratégia adicionada em uma semana precisa ter evidência de entrada e condição objetiva de encerramento, evitando que o trabalho permaneça indefinidamente em estado intermediário.

A.6 - Riscos da rotação de semanas

Foi incluído um controle específico para pivotagem. Justificativa: em um projeto de sete semanas, uma mudança tardia pode consumir semanas de modelagem e validação; por isso a mudança deve registrar evidência, impacto e novo critério de fechamento.

A.7 - Alteração do dataset na Semana 2

O dataset inicialmente associado ao ICMC foi substituído pelo Fake.br Corpus. Justificativa: o corpus possui 7.200 notícias com rigoroso pareamento por similaridade, permitindo a extração de assinaturas estilométricas. A limitação temporal do dataset (coleta até 2018) motivou a inclusão de uma fase paralela de Engenharia Reversa para mineração de dados mais recentes (2026).

A.8 - Classes versus categorias

A classe-alvo foi simplificada para Verdadeira/Falsa, enquanto Brasil, política, entretenimento, saúde e mundo permanecem como categorias temáticas. Justificativa: o dataset de origem separa veracidade de tema; misturar os dois criaria classes artificiais não sustentadas pela anotação original. [9]

A.9 - Possibilidade de múltiplos rótulos

Não foi adotado multi-rótulo na classe de veracidade. Multi-rótulo só será considerado para a dimensão temática se a anotação permitir múltiplos temas por notícia. Justificativa: uma técnica de modelagem não deve criar informação que não existe no rótulo de origem. [10]

A.10 - Referência do LDA

A sigla foi mantida como LDA (Latent Dirichlet Allocation) e recebeu referência a Blei, Ng e Jordan (2003). Justificativa: LDA é uma técnica de modelagem de tópicos, não uma classe de veracidade; por isso foi reposicionada como análise exploratória. [11]

A.11 - Referências do Quadro 4.3

Cada técnica de validação passou a ter fonte: Design Sprint/Google, Wizard of Oz, Shadow Mode, AI TRISM/Red Teaming e A/B Testing. Justificativa: o quadro deixa de ser apenas uma proposta do grupo e passa a distinguir definição da técnica de aplicação específica no Miop.IA.

A.12 - Registro da preferência pelo Fake.BR-Corpus

O documento registra a decisão da equipe técnica de descartar as 25 features originais do corpus Fake.br. Justificativa: as features originais foram geradas por bibliotecas defasadas. A equipe recalculou todas as variáveis utilizando o spaCy para garantir reprodutibilidade e evitar divergências de tokenização na inferência em ambiente de produção.